

Introduction

- 언어 모델의 활용이 확대됨에 따라, 하나의 모델이 다양한 태스크를 수행할 수 있도록 하는 멀티태스크 학습 기법에 대한 관심이 증가 → **LoRA[1] 모듈을 병합**하여 사용하는 방식이 일반적
- 기존 연구에서는 Mixture-of-LoRAs(MoA)와 같은 **Router 기반의 방식**이 주로 사용됨[2]. 이러한 방식은 높은 성능을 보이나, **라우터로 인해 학습 · 추론 시 추가적인 데이터와 자원이 필요함**.


Prompt Format – Question Answering

Context:
{context}
Question:
{question}
Answer:

- 이에 본 연구는 태스크별 입력 형식이 명확히 구별되는 경우, 멀티태스크 능력을 위한 **라우터 구조가 필수적이지 않을 것**이라는 가설을 세움.
- 이를 입증하기 위해 우리는 라우팅(routing) 없이 수행하는 3개의 수학적 LoRA 가중치 병합(merging) 전략을 제안하고 비교함.
- 다양한 NLP 태스크의 데이터셋에서 병합 방식에 따른 Multitask Score(※)를 측정한 결과, 언어모델이 일부 방식에서 라우터 없이도 병합된 모듈에서 원본 task-specific weight를 복원하여 높은 멀티태스크 능력을 보일 수 있음을 입증함.

Methods

Router-Free Merging Methods



(1) Concatenation: 태스크별 LoRA 모듈을 입력에 순차적으로 적용하고 alpha/rank 값으로 스케일링하여 합산

$$A_{\text{merged}} \cdot B_{\text{merged}} = \sum_{i=1}^N \frac{\alpha}{r_i} A_i B_i$$

(2) Weight Summing: 각각의 LoRA 모듈의 A, B행렬의 가중합을 새로운 모듈로 사용


$$A_{\text{merged}} = \sum_{i=1}^N w_i A_i, \quad B_{\text{merged}} = \sum_{i=1}^N w_i B_i$$

(3) SVD Merge: 특이값 분해(SVD)를 통해 저차원 근사를 수행함으로써 하나의 압축된 LoRA 모듈을 생성

$$\bar{W} = \frac{1}{N} \sum_{i=1}^N A_i B_i = U \Sigma V^T, \quad A_{\text{merged}} = \Sigma_{1:r} V_{:,1:r}^T, \quad B_{\text{merged}} = U_{:,1:r}$$


Results & Analysis

Model Scaling: 0.5B vs 1.5B



- 0.5B 모델에서는 MoA와 비교하였을 때 최대 70%에 불과한 성능
- 1.5B 모델에서는 Weight Summing 및 Concatenation 기반 병합 방식에서 MoA의 **최대 95%** 수준의 성능에 도달
- 일정 크기 이상의 모델은 라우터 없이 자체적으로 입력 형식에 드러난 태스크 정보를 활용할 수 있음을 보임

Task Scaling: 5-task vs 7-task



- 태스크 증가→MoA 제외, 모든 방식에서 multitask score 하락
- 태스크 개수가 증가함에 따라 병합된 모듈에서 원본 task-specific weight를 완벽하게 복원하기 어려워지는 것으로 해석됨

Full Results (1.5B, 7-task)

Model	Summarization (ROUGE)			Translation		QA (SQuAD)		Sentiment	NLI	Paraphrase	Commonsense
	R-1	R-2	R-L	BLEU	EM	F1	Acc.	Acc.	Acc.	BLEU	Acc.
Base	0.161	0.047	0.119	0.016	15.4	34.9	0.004	0.000	0.109		0.280
MoA	0.276	0.099	0.201	0.145	79.2	83.0	0.930	0.865	0.572		0.734
SVD Merge	0.159	0.046	0.118	0.097	62.6	71.6	0.868	0.053	0.553		0.616
weight summing	0.151	0.064	0.124	0.103	72.0	77.0	0.866	0.647	0.508		0.510
Concatenation	0.194	0.077	0.157	0.105	72.6	78.2	0.896	0.578	0.511		0.300
Individual LoRA (Oracle)	0.278	0.100	0.203	0.139	79.4	83.1	0.930	0.867	0.573		0.746

※ Multitask score: Individual LoRA(oracle) 값으로 정규화한 task별 대표 metric들의 평균값으로 정의함.

Ablation Study

Method	Summarization (ROUGE)			Translation		QA (SQuAD)		Sentiment Acc.	NLI Acc.
	R-1	R-2	R-L	BLEU	EM	F1			
Concatenation	0.278	0.103	0.210	0.119	78.8	83.6	0.932	0.780	
w/o Scaling	0.225	0.077	0.176	0.092	75.8	81.2	0.888	0.578	
weight summing	0.276	0.102	0.206	0.121	79.8	83.3	0.928	0.796	
Averaged	0.222	0.080	0.174	0.088	76.2	81.8	0.920	0.708	


높은 multitask score를 기록한 두 방식에서 세부설정을 변경하여 ablation study를 진행

Concatenation: LoRA 모듈의 alpha scaling을 제거

Weight Summing: 합산 후 태스크 개수로 나눈 평균값을 사용

- 위와 같은 변형을 가한 결과, 모든 task에서 성능 지표가 유의미하게 하락
- 원본 LoRA 모듈을 최대한으로 보존하면서 병합하는 것이 router-free method의 작동 조건임을 알 수 있음

Cosine Similarity Analysis across Tasks



7개의 task에 대해 각각 학습된 LoRA 모듈 간의 cosine similarity 측정 (Summarization, Translation, QA, Sentiment Analysis, NLI) + (Paraphrasing, Commonsense Reasoning)

- 서로 다른 태스크 간의 코사인 유사도가 0에 근접
- ➔ 태스크별 입력 형식에 확실한 차이를 두는 것에 따른 결과
- 이러한 **직교성**은 가중치를 선형적으로 결합하는 경우 최소한의 간섭으로 병합을 수행할 수 있는 이유로 해석됨

References

- [1] Hu, E. J. et al. LoRA: Low-Rank Adaptation of Large Language Models. In Proceedings of the 10th International Conference on Learning Representations (ICLR), 2022.
- [2] Feng, W. et al. Mixture-of-LoRAs: An Efficient Multitask Tuning Method for Large Language Models. Proceedings of the 2024 Joint International Conference on Computational Linguistics and Language Resources Evaluation (LREC-COLING 2024), 11371-11380, 2024.